

Teoria de Resposta ao Item (TRI) na prática

Rasch (1PL) vs 2PL com validação e diagnóstico completo

Autor: Gilson Machado Monteiro | Especialização em Estatística Aplicada — PUC Minas | 2025

Contextualização

Em avaliações educacionais e instrumentos psicométricos, não basta contar acertos: é fundamental compreender como cada item se comporta (dificuldade, poder de discriminação) e em que faixa de habilidade o teste mede com maior precisão. É exatamente esse o propósito da **Teoria de Resposta ao Item (TRI)**: modelar respostas observadas a partir de um traço latente (θ) e parâmetros do item.

No modelo **2PL**, a probabilidade de acerto é:

$$P(Y_{pi}=1 \mid \theta_p, a_i, b_i) = \sigma(a_i(\theta_p - b_i)) \text{ onde } \sigma(x) = 1/(1+e^{-x})$$

A precisão do teste é analisada via **Informação do Teste (TIF)** e **Erro Padrão de Medida (SEM)**:

$$SEM(\theta) = 1 / \text{sqrt}(TIF(\theta))$$

O Projeto

TRI aplicada a um conjunto de respostas dicotômicas (0/1) com **239 respondentes × 60 itens** (taxa média de acerto $\approx 0,422$), estimando modelos Bayesianos em PyMC e conduzindo avaliação completa do ajuste.

Etapas Metodológicas

- Calibração dos modelos Rasch (1PL) e 2PL via PyMC com amostragem NUTS
- Comparação de modelos por LOO (leave-one-out cross-validation)
- Interpretação via ICC (curvas características dos itens) e TIF/SEM
- Validação por Posterior Predictive Checks (PPC): nível do item e nível global
- Diagnóstico de pressupostos: PCA (uni vs multidimensionalidade) e Yen's Q3 (dependência local)

Principais Achados

Métrica	Valor	Interpretação
N respondentes	239	Tamanho amostral adequado
J itens	60	Escala de tamanho médio
Taxa média de acerto	0,422	Dificuldade moderada
elpd_loo 2PL	-8.908,98	Melhor poder preditivo
elpd_loo Rasch	-8.995,95	Inferior ao 2PL
Δelpd (2PL – Rasch)	86,97	Diferença substancial (> 4)
Peso 2PL (BB-pseudo-BMA)	1,000	2PL domina completamente
Pico TIF	$\theta \approx -0,37$	Maior precisão em hab. baixa-média
TIF no pico	12,35	Precisão elevada
SEM no pico	0,285	Erro padrão baixo

PPC por item (fora env. 90%)	0 de 60	Ajuste local excelente
Pares Q3 $\geq$ 0,20	2	Dependência local pontual

Diagnóstico PPC Global

Estatística	Observado	Envelope PPC 90%	Dentro?
Média do score total	25,30	[25,47 – 26,21]	Não
DP do score total	6,74	[6,97 – 7,62]	Não

Conclusão

Os resultados sustentam que o **2PL calibra bem no nível do item** (0/60 fora do envelope preditivo), mas o comportamento agregado do score total sugere que um modelo estritamente unidimensional pode ser insuficiente — média e DP observados ambos fora do envelope de 90%, aliados à ausência de fator dominante na PCA e dependência local pontual (2 pares com $Q3 \geq 0,20$).

Esses achados abrem espaço para extensões como **MIRT** (multidimensional IRT) ou modelo **bifator**, que permitiriam separar um traço geral de traços específicos por domínio — hipótese compatível com instrumentos educacionais amplos.

Stack Técnica

Modelagem: PyMC 5, ArviZ | **Estatística:** scipy, pandas, numpy | **Visualização:** matplotlib | **Ambiente:** Google Colab

Repositório: github.com/gilsonmm6/tri-irt-bayesian